Alzheimer Hastalığının Erken Tespitinde 3D CNN ve Makine Öğrenmesi Tabanlı Çok Modelli Geç Füzyon Mimarisi: OASIS-3 Üzerinde Kapsamlı Bir Karşılaştırmalı Çalışma

A Multimodal Late-Fusion Architecture for Early Alzheimer Detection: A Comprehensive Study on OASIS-3

ÖZET

Alzheimer hastalığının erken tespit edilmedi hastalığının ilerleyişini yavaşlatmak için kritik öneme sahiptir. Güncel klinik süreçler hastalığının tedavi sürecinde uzman hekimlerin nörogörüntüleme verileri ile klinik testleri bir bütün halinde ele alınması gerekliliğinden dolayı doktorlar üzerinde bir iş yükü oluşturur. Bu duruma destek olmak amacıyla , OASIS-3 boylamsal (longitudinal) veri setinde bulunan klinik veriler ve T1w ağırlıklı MRI görüntüleri kullanılarak multimodal ağırlıklı geç ayrıştırma modeli tasarlanmıştır .Bu çalışma kapsamında MR verileri için özgün bir Custom 3D CNN ve MedicalNet ön-eğitimli Resnet50 modelleri ,öteki taraftan klinik veriler için ise MLP, XGBoost, LightGBM, CatBoost, TabNet, FT-Transformer ve Random Forest olmak üzere yedi farklı algoritma Optuna hiperparametre optimizasyonu ile beraber ayrı ayrı eğitilmiştir. Modellerin tekil performanslarını artırmak için geç füzyon (late-fusion) yaklaşımı kullanılmıştır. Softmax çıktıları α=0.3 MRI ve α=0.7 klinik ağırlığıyla birleştirilerek 2 MRI ve 7 klinik tabanlı ağ ile 14 farklı MRI × Klinik kombinasyonu test edilmiştir.Resnet50 + XGBoost kombinasyonuyla en yüksek dengeli doğruluk (Balanced Accuracy) değeri olan %78.13 bulunmuş ve F1 skoru 76.34 olarak ölçülmüş ayrıca 5-katlı çapraz doğrulamada 76.8 ± 2.1 değerine ulaşılmıştır. En yüksek genel doğruluk (Accuracy) ise CustomCNN + RandomForest kombinasyonuyla %88.76 olarak ölçülmüştür. Aynı hastaya ait verilerin eğitim ve test setlerine karışarak veri sızıntısı yapmasını engellemek için veri bölme işlemi olarak StratifiedGroupKFold yöntemi kullanılmıştır. Veri setinde hedef özelliği doğrudan işaret eden özellikler elimine edilerek hedef sızıntısının önüne geçilmiştir. Ayrıca sistemin şeffaflığını arttırmak ve karar mekanizmasının doğruluğu görebilmek için Grad-Cam ısı haritaları ile görselleştirilmiştir. Bu çalışma, boylamsal veri setlerinde sıklıkla karşılaşılan veri sızıntısı problemini çözerek literatüre daha güvenilir bir metodoloji sunmakta ve açıklanabilir yapay zeka ile hekimler için özgün bir klinik karar destek aracı sağlamaktadır.

Anahtar Kelimeler Alzheimer Erken Tespit · OASIS-3 · 3D CNN · XGBoost · LightGBM · CatBoost · Geç Birleşim (Late Fusion) · Optuna · Açıklanabilir Yapay Zekâ · Derin Öğrenme

GİRİŞ

Alzheimer hastalığı (AH) dünyada 55 milyondan fazla kişiyi etkileyen ve nöron kaybına yol açtıktan sonra geri dönüşü olmayan bir nörodejeneratif hastalıktır [1].Hastalığının nörolojik belirtileri ,hastalığın biyolojik kökeninden yıllar sonra ortaya çıkmaktadır [2]. Bundan dolayı semptomları hastalığın belirgin olmadığı evrelerde gözlemleyebilmek erken tanı ve tedavi planlaması için kritik öneme sahiptir.

Doğru bir tanıya ulaşmak için uzman hekimlerin ve MR görüntülerinden çıkarılan radyolojik biyobelirteçleri (hipokampal atrofi, ventriküler genişleme, kortikal incelme) nöropsikolojik testlerle (MMSE, CDR, MoCA) birlikte ve çok boyutlu olarak değerlendirmeleri gerekir[3]. Artan hasta yoğunluğu ve uzman hekim yetersizliği bu değerlendirme sürecini zorlaştırmakta, tanı gecikmelerine ve hata riskine zemin hazırlayabilmektedir. Son on yılda derin öğrenme tabanlı bilgisayar destekli tanı sistemleri (CAD) bu soruna yardımcı olmak amacıyla hızla geliştirilmiştir [4].

Bununla beraber, literatür taramasında üç temel yöntemsel sorun yaşanmaktadır. (1) Boylamsal (longitudinal) verilerde hasta temelli izolasyonun yapılmamasına bağlı olarak aynı hastanın farklı setlere karışmasıyla oluşan kimlik sızıntısı (data leakage) [5], (2) veri setinde tanı hedefini doğrudan ele veren (kopya niteliğindeki) özelliklerin veri ön işlemede elimine edilmemesi sonucu gerçekleşen hedef sızıntısı (target leakage) ve (3) farklı modalitelerin birleştirilmesi sırasında, daha kolay öğrenilen veri türlerinin öne çıkarak füzyonda baskınlık (modality dominance) oluşturması [6].

Bu çalışmada literatürdeki bahsedilen sorunlar ele alınarak , OASIS-3 veri seti üzerinde Ağırlıklı Geç Füzyon mimarisi geliştirilmiştir.

1.1. Çalışmanın Katkıları

Bu çalışmanın literatüre sunduğu özgün katkılar şu şekildedir:

- İki adet MRI modeli (Custom 3D CNN, ResNet50-MedicalNet) ve yedi adet klinik model (MLP, XGBoost, LightGBM, CatBoost, TabNet, FT-Transformer, Random Forest) kullanılarak toplam 14 farklı MRI x Klinik geç füzyon kombinasyonu ile kapsamlı model karşılaştırılması yapılmıştır.

- StratifiedGroupKFold ile hasta bazında izolasyon sağlanarak kimlik sızıntısının, veri setinden bazı özellikler çıkarılarak da hedef sızıntısının önüne geçilmiştir.

- Tüm modellerde Optuna MedianPruner kullanarak hiperparametre optimizasyonu yapılmıştır .

- Aşırı Öğrenmeyi Önleme için Dropout, EMA, Erken Durdurma, Veri Artırma ve Hasta Bazlı İzolasyon gibi on farklı strateji bir arada kullanılmıştır.

- Grad-Cam ile modelin MR görüntülerindeki odak bölgeleri görselleştirilerek , karar mekanizmasının klinik doğruluğu kanıtlanmıştır.

- Accuracy, Balanced Accuracy, Precision, Recall, F1, ROC-AUC ve 5-katlı CV Mean ± Std metrikleri ile her model için performans analizi yapılmıştır.

2. LİTERATÜR TARAMASI

2.1. Alzheimer Hastalığında Klinik ve Radyolojik Teşhis Süreci

Alzheimer hastalığının tanımlanması için hastanın bilişsel ve fiziksel durumunun tüm detaylarıyla ele alınmasını gerekmektedir.

Nöropsikolojik testler (MMSE, CDR, MoCA, GDS) hastanın bilişsel düzeyini sayısallaştırırken , T1-ağırlıklı MR görüntüleri üç temel anatomik biyobelirteci ortaya koymaktadır: (1) hastalığın en erken radyolojik belirtisi olan beynin hipokampal bölümünde atrofi , (2) beyin dokusunun erimesiyle genişleyen lateral ventriküller (3) hastalık ilerledikçe belirginleşen serebral kortikal incelme. Bu iki veri türünün beraber ele alınması ve yorumlanması modern nörolojik tanının temelini oluşturmaktadır [LaMontagne, 2019].

2.2. Literatürde Karşılaşılan Yöntemsel Sorunlar

Literatür tarandığında daha önce yapılan çalışmalarda yüksek başarı oranlarının görünmesinin üç temel nedenden kaynaklandığı gözlenmektedir: (1) aynı hastanın verilerinin hem eğitim hem de test setinde bulunması (kimlik sızıntısı), (2) CDR-SB veya MMSE gibi hedef özellik ile yüksek korelasyon gösteren özelliklerin elimine edilmemesi (hedef sızıntısı) ve basit vektör birleştirme yöntemlerinin baskın modaliteye ağırlık vererek diğer veriyi göz ardı etmesidir.

2.3. Literatürdeki Boşluk ve Çalışmanın Konumlanması

Literatür taramasında şu eksiklikler belirlenmiştir: (1) Sayısal klinik verilerin eğitiminde XGBoost, LightGBM, CatBoost, TabNet veya FT-Transformer gibi algoritmaların Alzheimer çalışmalarında kullanılması son derece yetersizdir. (2) OASIS-3 gibi boylamsal (longitudinal) kohort verisinde hasta bazlı izolasyon uygulanarak elde edilmiş 3-sınıflı çalışma sayısı yetersizdir. (3) Füzyon ağırlığının (α) optimize edilmesi ve veri türlerinin katkısı ablasyon testi ile analizi edilip raporlanması nadirdir. Bu çalışma , bahsedilen eksiklikler üzerine tasarlanmıştır.

3. MATERYAl VE METOT

3.1. Veri Seti

Bu çalışmada Washington Üniversitesi Knight ADRC tarafından açık erişime sunulan OASIS-3 (Open Access Series of Imaging Studies) boylamsal (longitudinal) kohort veri seti kullanılmıştır [4]. Veri setinde ,yaşları 42 ila 95 arasında değişen 1.360 hastadan alınmış, 30 yılı aşkın bir süreyi kapsayan 3.692 multimodal kayıttan oluşmaktadır. MR verilerinin eğitimi kısmında T1-ağırlıklı görüntüler , klinik verilerin eğitiminde ise demografik özellikler, bilişsel testler (MMSE, MoCA, CDR, GDS), işlevsel değerlendirme (FAQ, CDR-SB) ve genetik belirteçler (APOE4 genotipi) yer almaktadır.

Hastaların CDR skoruna göre üç sınıfa ayrılması ve her sınıfın eğitim/test dağılımı Tablo 1'de özetlenmektedir.

Tablo 1. OASIS-3 Veri Seti Sınıf Dağılımı ve Eğitim/Test Bölünmesi

Sınıf	Örnek Sayısı	Oran (%)	CDR Skoru	Split (Eğ./Test)
Normal (CN)	2,950	%79.9	0	2,360 / 590

Hafif / MCI	469	%12.7	0.5	375 / 94
Orta/Ağır	273	%7.4	> 0.5	218 / 55
Toplam	**3,692**	**100%**	–	**2,953 / 739**

'Normal' sınıfının yüzdesinin %79.9 olması ciddi bir sınıf dengesizliği yol açmaktadır. Bu dengesizliğin çözümü , Bölüm 3.4'te ele alınmıştır.

MR görüntülerinin tarihleri ile klinik verilerinin ziyaret tarihleri arasındaki zaman farkından ötürü , her MR kaydı için ±180 günlük tolerans verilerek eşleştirme yapılmıştır.Bu tolerans eşiği, Alzheimer çalışmalarında klinik olarak geçerli ve yaygın kabul gören bir yaklaşımdır [1][2].

3.2. Veri Ön İşleme

3.2.1. Klinik Veri Ön İşleme

OASIS-3'te bulunan 18 farklı CSV tablosu ortak anahtar üzerinden tek bir tabloda birleştirilmiştir. Tekilleştirme işlemi OASISID x age_at_visit kolonlarıyla gerçekleştirilmiştir. %20'den fazla eksik değeri olan özellikler çıkarılmış; kalan özelliklerin eksik verileri ileri doldurma yöntemiyle doldurulmuştur. Hedef sızıntısına neden olabilecek CDR, CDR-SB vb özellikler veri setinden çıkarılmıştır. Sonuç olarak klinik özellik setinde 84 değişken bulunmaktadır.

İlaç verileri için PCA tabanlı gömme yöntemi kullanılmıştır: 2.692 benzersiz ilaç ismi nn.Embedding kullanılarak 16 boyutlu vektörler haline dönüştürülmüştür.Bu vektörler PCA ile 8 bileşene indirgenmiştir. Sayısal değişkenler MLP ve dikkat tabanlı modeller (TabNet, FT-Transformer) için QuantileTransformer ile normalize edilmiş ölçeklenmeden etkilenmeyen ağaç tabanlı modeller ise ham haliyle kullanılmıştır. Veri sızıntısını engellemek için tüm normalizasyon parametreleri sadece eğitim setinden öğrenilmiştir.

3.2.2. MR Görüntüsü Ön İşleme

Farklı boyutlardaki T1-ağırlıklı MR görüntüleri modele verilmeden önce beş adımlı ön işlemeden geçirildi. Öncelikle anatomik eksenler RAS standardına dönüştürüldü , ardından vokseller 1 mm iztropik boyuta getirildi. Görüntüdeki boş kısımlar kırpılarak yalnızca beyin dokusu geriye bırakıldı. Tüm hacimler 176×240×256 boyutundan 128×128×128 boyutuna getirildi. Son olarak piksel değerleri %1–%99 aralığında kırpılıp z-skoru kullanılarak normalize edildi.

Aşırı öğrenmeyi önlemek için eğitim sırasında MONAI kütüphanesiyle [5] veri artırma teknikleri uygulandı. Kullanılan tekniklerin gerekçeleri Tablo 2'de verilmiştir.

Tablo 2. MR Görüntüsü Veri Artırma (Data Augmentation) Teknikleri ve Klinik Gerekçeleri

Teknik	Uygulama Olasılığı	Parametre	Klinik Gerekçe
RandFlip (Sagital)	p = 0.50	Eksen: 0	Beyin anatomisi sol-sağ simetridir; yönelim bağımsızlığı sağlar.
RandFlip (Koronal)	p = 0.20	Eksen: 1	Ön-arka simetri MR pozisyon varyasyonlarını taklit eder.
RandAffine	p = 0.20	Rotasyon ±0.04 rad, Ölçek ±%4	Hasta baş pozisyonundaki küçük farklılıkları simüle eder.
RandScaleIntensity	p = 0.10	Katsayı ±0.08	Farklı MR cihazlarının kontrast farklılığını taklit eder.
RandGaussianNoise	p = 0.10	μ=0, σ=0.01	Gerçek MR termal gürültüsünü (thermal noise) simüle eder.

3.3. Model Mimarileri

3.3.1. Custom 3D CNN

OASIS-3 veri setindeki MR görüntülerinden beyin atrofisini yakalayabilmek için sıfırdan bir 3D CNN mimarisi tasarlandı. Bu mimari de birkaç temel sorun göz önünde bulunduruldu. (1) 3D MR verileri bellekte çok fazla yer kapladığı için eğitim sırasında küçük yığın boyutları (batch size) kullanılması gerektiğinden klasik Batch Normalization katmanları yerine GroupNorm tercih edildi. (2) Ağın derinleşmesi durumunda gradyanların zayıflayıp öğrenmenin durma noktasına gelmesi karşı olarak her blok arasına artık bağlantılar (residual connections) eklendi. Böylece gradyanlar erken katmanlara doğrudan ulaşabildi.(3) Alzheimer hastalığının en belirgin özellikleri beyinde hipokampüs küçülmesi ve ventrikül genişlemesi gibi bölgesel değişimlerdir. Modelin bu önemli bölgelere daha fazla dikkat etmesi için Squeeze-and-Excitation (SE) dikkat blokları eklendi. Bu bloklar, her bir özellik haritasının önemini tartarak modeli klinik açıdan anlamlı bölgelere yönlendirdi.(4) Modelin eğitim verisini ezberleyerek aşırı öğrenme yapmasını önlemek için aşamalı bir Dropout3D uygulandı. İlk katmanlarda %5 olan dropout oranı ağ derinleştikçe %10 ve %15'e kadar çıkarıldı. Bu sayede erken katmanlarda özellikler korunurken , son katmanlarda aşırı öğrenmenin önüne geçildi.

MR görüntülerinden özellik çıkarımı yapması için tasarlanan 3D CNN mimarisinin katman yapısı , çıktı boyutları ve parametre sayıları Tablo 3'de verilmiştir.

Tablo 3. Custom 3D CNN Katman Detayları

Katman	Kernel	Stride	Aktivasyon	Çıktı Boyutu	Norm.	Parametre
InstanceNorm3d (Giriş)	–	–	–	1×128³	InstanceNorm	2
Stem Conv3d	3³	2	ReLU	32×64³	GroupNorm	928
ResBlock 1-1 (Conv3d×2)	3³	2	ReLU	64×32³	GroupNorm	168,320
ResBlock 1-2 (Conv3d×2)	3³	1	ReLU	64×32³	GroupNorm	221,440
ResBlock 2-1 (Conv3d×2)	3³	2	ReLU	128×16³	GroupNorm	672,512
ResBlock 2-2 (Conv3d×2)	3³	1	ReLU	128×16³	GroupNorm	885,248
SE Block (r=8)	–	–	ReLU+Sigmoid	128×16³	–	4,096
ResBlock 3-1 (Conv3d×2)	3³	2	ReLU	256×8³	GroupNorm	2,688,512
ResBlock 3-2 (Conv3d×2)	3³	1	ReLU	256×8³	GroupNorm	3,539,968
SE Block (r=16)	–	–	ReLU+Sigmoid	256×8³	–	8,192
Global Avg Pool	–	–	–	256×1	–	0
FC-1 (Linear)	–	–	ReLU	128	Dropout(0.20)	32,896

FC-2 (Linear)	–	–	Softmax	3	–	387
TOPLAM	–	–	–	–	–	**8,222,501**

3.3.2. ResNet50 (MedicalNet)

23 farklı tıbbi veri seti üzerinden ön eğitilmiş (pretrained) MedicalNet Resnet50 ağı ikinci MR modeli olarak kullanıldı. MedicalNet'in tercih nedeni ise bu ağın MR , BT ve PET gibi tıbbi veriler ile eğitilmiş olmasından dolayı beyindeki atrofi ve ventriküler genişleme gibi bulguları tanımlamasıdır. Bu model MONAI kütüphanesinden spatial_dims=3, n_input_channels=1, shortcut_type=B parametreleriyle kullanılmıştır.Probleme özgü yeni karar mekanizması yaratmak amacıyla modelden standart sınıflandırıcı çıkarıldı , ardından ağdan gelen 2048 boyutlu öznitelik vektörü sırasıyla 512 ve 128 nöronlu iki gizli katmandan geçirilerek 3 sınıflı hedefimize indirgendi. Donanım kısıtlarından dolayı eğitimde küçük yığın boyutu (batch=4) kullanıldı. Az veride kararsız çalışan klasik BatchNorm yerine LayerNorm ve Gelu kullanıldı. Ayrıca MedicalNet'in önceden öğrendiği ağırlıkları bozmamak adına modelin mevcut BatchNorm katmanları eğitime donduruldu.Ön eğitimden gelen bilgilerin ezberlenerek unutulmaması (catastrophic forgetting) için üç fazlı kademeli bir strateji (gradual unfreezing) yürütüldü. İlk fazda sadece yeni eklediğimiz kafa eğitildikten sonra ikinci fazda modelin son bloğu olan Layer 4 devreye alındı. Son olarak üçüncü fazda ise daha derin özellikleri bulan Layer 3 eğitime dahil edildi. Her yeni fazda optimizer sıfırlandı. Ardından Cosine Annealing ile öğrenme oranları katmanlara göre ayarlandı.Eğitim sürecini kararlı kılmak için kullanılan teknikler; karışık hassasiyet (mixed precision), gradyan biriktirme (efektif batch=16) ve EMA (decay=0.998)'dir.Veri setindeki sınıf dengesizliğinin önüne geçmek için WeightedRandomSampler kullanıldı. Modelin genelleme yapabilmesi için ise label_smoothing (0.05) ve weight_decay (3×10^{-4}) parametreleri kullanılarak aşırı öğrenmenin önüne geçildi.

Son olarak, hiperparametre optimizasyonu Optuna ile gerçekleştirip modeli en kararlı hale getiren parametreler bulundu.

Ön-eğitimli Resnet50 modelinin yeni veri setine adapte olup önceden öğrenilmiş ağırlıkların ani güncellemelerle bozulmasını engellemek amacıyla kademeli katman çözme stratejisi uygulanmıştır . Bu strateji Tablo'4 de belirtilmiştir.

Tablo 4. ResNet50 (MedicalNet) 3-Faz Eğitim Stratejisi

Faz	Eğitilen Katmanlar	Optimizer LR Grupları	Epoch	Amaç
Faz 1	Yalnızca Head (FC)	Head LR: 1e-4	10	Sınıf. başlığını ısıt, backbone dondur
Faz 2	Layer4 + Head	Layer4: 2e-5 / Head: 5e-5	20→30	Yüksek seviye özellik adaptasyonu
Faz 3	Layer3 + Layer4 + Head	Layer3: 8e-6 / Layer4: 2e-5 / Head: 8e-5	30→75	Tam ince ayar, düşük LR ile

3.3.3. Klinik Modeller

Literatürdeki MLP yaklaşımının yetersizliğini gidermek ve klinik verilerdeki korelasyonları farklı açılardan modellemek için derin öğrenme ve karar ağaçları mekanizmalarından oluşan yedi farklı

algoritma mimarisi kullanılmıştır. Tüm modeller hiperparametre optimizasyonu ile optimize edilip, sınıf dengesizliğini gidermek adına her algoritmada örnek ağırlıklandırma (`sample_weight`) veya otomatik sınıf dengeleme (`class_weight="balanced"`, `auto_class_weights="Balanced"`) teknikleri kullanılmıştır.

MLP modeli için beş gizli katmanı (288→96→352→512→128) olan bir mimari kurulmuş ve her katmanda LayerNorm ve LeakyReLU kullanılmıştır. Modelin klinik verileri daha iyi öğrenebilmesi için klinik özelliklerin dağılımları QuantileTransformer kullanılarak Gauss dağılımına dönüştürüldü; sınıf dengesizliği problemini giderebilmek için kayıp fonksiyonu olarak Focal Loss ve yerel minimumlardan kaçınabilmek için ise zamanlayıcı olarak CosineAnnealingWarmRestarts tercih edilmiştir.

TabNet algoritmasında sıralı dikkat mekanizması ve entmax maskeleme kullanılarak her karar adımında önemli klinik özelliklerin seçilmesi sağlanmıştır.

FT-Transformer ise her klinik özelliğin Feature Tokenizer ile öğrenilebilir vektörlere dönüştürüldükten sonra çok başlıklı öz-dikkat mekanizması kullanılarak klinik tablo üzerindeki korelasyonların yakalanması sağlanmıştır.

XGBoost, derinliğe göre büyüyen ağaç yapısı ve L1/L2 düzenlileştirme ile eğitilmiştir.

LightGBM için yaprak bazlı (leaf-wise) büyüme ve histogram tabanlı bölme metotları kullanıldığı için klinik veriler üzerinde hızlı ve yüksek doğruluklara ulaşan sonuçlar elde edilmiştir.

CatBoost tarafında simetrik ağaç (SymmetricTree) yapısı ile sıralı artırma (ordered boosting) metotları kullanılarak modelin genellemesi artırılarak hedef sızıntılarının (target leakage) önüne geçilmiştir.

Son olarak Random Forest, 800 ağaç ve entropi ölçütü kullanılarak eğitilmiştir. Random Forest'ın tercih edilme nedeni, gürültülü verilere karşı stabil bir performans referansı sunmasıdır.

Eğitilen bu yedi farklı modelden elde edilen öznitelikler ve sınıf olasılıkları, çalışmanın bir sonraki aşaması olan multimodal füzyon (MRI + Klinik) mimarisi için temel oluşturmuştur.

Kullanılan modellerin mimarileri , hiperparametre için kullandıkları parametreler ve sınıfı dengesizliğini giderebilmek adına kullanılan algoritmalar Tablo 5' te verilmiştir

Tablo 5. Klinik Modellerin Mimari ve Optimizasyon Özeti

Model	Temel Mekanizma	Optuna Arama Alanı	Sınıf Dengeleme
MLP	5 gizli katman (288→96→352→512→128), LayerNorm + LeakyReLU, Balanced Focal Loss	lr, dropout, katman boyutları, focal gamma	WeightedRandomSampler
XGBoost	Derinliğe göre büyüyen ağaç yapısı, L1/L2 düzenlileştirme	n_estimators, max_depth, lr, subsample, colsample_bytree, reg_alpha/lambda	sample_weight (ters frekans)
LightGBM	Yaprak odaklı (leaf-wise) büyüme, histogram tabanlı algoritma	n_estimators, num_leaves, lr, subsample, subsample_freq, reg	sample_weight (ters frekans)

CatBoost	Simetrik ağaç (SymmetricTree), sıralı artırma (ordered boosting)	iterations, depth, lr, l2_leaf_reg, bagging_temperature, grow_policy	auto_class_weights=Balanced
TabNet	Sıralı dikkat mekanizması (Sequential Attention), entmax maskeleme	n_d/n_a, n_steps, gamma, lambda_sparse, n_independent, n_shared, lr	weights=1 (otomatik dengeleme)
FT-Transformer	Feature Tokenizer + çok başlıklı öz-dikkat (Multi-Head Attention), CLS token	d_token, n_heads, n_layers, dropout, lr, weight_decay, label_smoothing	WeightedRandomSampler
Random Forest	800 bağımsız ağaç, entropi ölçütü, bootstrap örnekleme	n_estimators, max_depth, min_samples_split, max_features, criterion	class_weight=balanced_subsample

3.4. Aşırı Öğrenme Önleme Stratejileri

Bu çalışmada aşırı öğrenme problemi modelin mimarisi ve veri düzeyi ile ele alınmıştır . Uygulanan her strateji ,amacı ve parametresiyle birlikte Tablo 6'de sunulmaktadır.

Tablo 6. Aşırı Öğrenme Önleme Stratejileri

Strateji	Modeller	Parametre / Ayar	Etki
Dropout (Spatial/Standard)	CNN, MLP, FT-T	p = 0.05–0.20	Nöron co-adaptation önler
Weight Decay (L2)	Tüm modeller	λ = 1e-4 – 1e-3	Ağırlık büyümesini kısıtlar
Early Stopping	Tüm modeller	Patience = 25–30 epoch	Doğrulama kaybı dibe vurduğunda durur
Label Smoothing	CNN, MLP	ε = 0.05–0.10	Aşırı güvenli sınıflandırmayı engeller
WeightedRandomSampler	CNN, MLP	Sınıf frekansının tersi	Baskın sınıf ezberini önler
GroupKFold (Hasta İzolasyonu)	Tüm modeller	5-Fold dış / 4-Fold iç	Kimlik sızıntısını ortadan kaldırır
Data Augmentation	CNN	5 teknik (bkz. Tablo 2)	Uzamsal çeşitlilik artırır
EMA (Exponential Moving Avg)	ResNet50	decay = 0.998	Ağırlık gürültüsünü düzleştirir
Gradient Clipping	CNN, ResNet50	max_norm = 1.0	Gradyan patlaması önler
Balanced Focal Loss	MLP	γ = 1.0→5.0 (dinamik)	Zor örneklere odaklanmayı artırır

3.5. Hiperparametre Optimizasyonu (Optuna)

Tüm modeller Optuna [Akiba, 2019] hiperparametre optimizasyonu ile optimize edilmiştir. MedianPruner stratejisi ile verimsiz denemeler budanmıştır.Tüm modellerin hiperparametre arama alanları ve Optuna tarafından seçilen değerler Tablo 7'te ayrıntılı biçimde raporlanmaktadır.

Tablo 7. Model Hiperparametreleri: Optuna Arama Alanı ve Seçilen Değerler

Model	Hiperparametre	Optuna Arama Aralığı	Seçilen Değer
Custom 3D CNN	Öğrenme Oranı (lr)	[1e-4, 1e-3] (log)	1e-3
	Weight Decay	[1e-5, 1e-3]	1e-4
	Dropout	[0.10, 0.40]	0.20
	Optimizer	AdamW	AdamW
	Scheduler	OneCycleLR	OneCycleLR
	Eğitim Epoch	[50, 200]	150
ResNet50 (MedicalNet)	Head lr	[5e-5, 2e-4] (log)	1e-4
	Layer4 lr	[5e-6, 5e-5]	2e-5
	Backbone lr	[2e-6, 2e-5]	8e-6
	Dropout	[0.25, 0.40]	0.30
	EMA Decay	[0.995, 0.999]	0.998
	Phase1 Epoch	[5, 15]	10
	Phase2 Epoch	[20, 35]	30
MLP	Katman Konfigürasyonu	[32-512] × 2-5 katman	288-96-352-512-128
	Dropout	[0.10, 0.50]	0.2929
	lr	[1e-4, 5e-3] (log)	8.4e-4
	Focal Gamma	[1.0, 3.0]	2.1
XGBoost	n_estimators	[100, 1000]	700
	max_depth	[3, 10]	6
	learning_rate	[1e-4, 0.30] (log)	0.089
	subsample	[0.4, 1.0]	0.82
	colsample_bytree	[0.4, 1.0]	0.71
Random Forest	n_estimators	[100, 1200]	900
	max_depth	[5, 30]	20
	max_features	{sqrt, log2, None}	sqrt
	class_weight	{balanced, balanced_subsample}	balanced_subsample
FT-Transformer	d_token	[32, 128]	64
	n_heads	{4, 8}	8
	n_layers	[2, 4]	3

	Dropout	[0.10, 0.40]	0.283
LightGBM	n_estimators	[100, 1500]	700
	learning_rate	[1e-4, 0.30] (log)	0.22
	num_leaves	[15, 127]	79
CatBoost	iterations	[200, 2000]	1000
	learning_rate	[1e-4, 0.30] (log)	0.26
	depth / grow_policy	[3, 10] / {Sym, Depth, Loss}	4/Sym

3.6. Geç Füzyon (Late Fusion) Stratejisi

Radyolojik MRI görüntüleri ile sayısal klinik verilerin karar verme aşamasında birleştirilmesini sağlayan geç füzyon (late-fusion) yaklaşımı, her iki veri türünün de birbirini baskılamadan ortak bir tanıya katkı sunmasına olanak tanır. Bu yaklaşım MRI ve klinik modelleri tamamen bağımsız optimize edildiği için her model test setine ait kendi sınıf olasılıkları (softmax çıktıları) üretmektedir. Bu olasılıklar ağırlıklı ortalama ile birleştirilerek nihai bir olasılık skoru ve sınıflandırma sonucu elde edilmektedir.

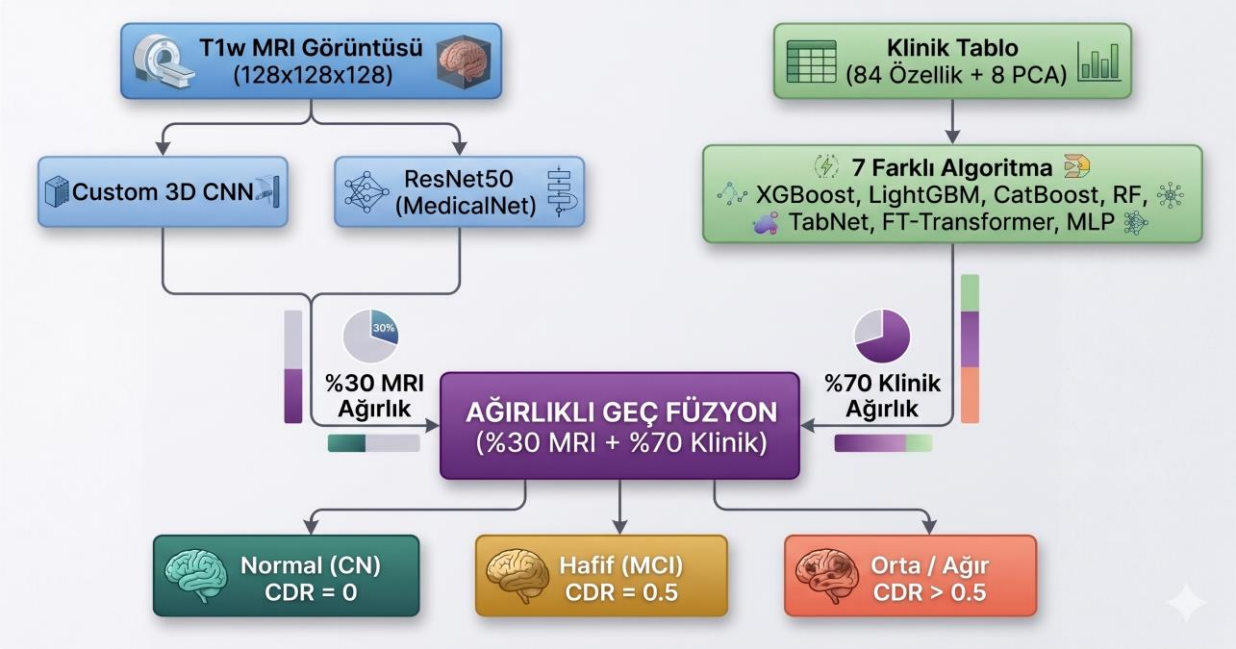
$$P_{final} = \alpha \times P_{MRI} + (1 - \alpha) \times P_{Clinic}\,,\ \alpha = 0.3$$

α değerinin 0.3 olarak seçilmesi MRI modeline %30 , klinik modele %70 ağırlık verilmesi demektir. Bölüm 4.4'teki ablasyon analizinde bu seçim nicel olarak doğrulanmaktadır. Geç Füzyon yaklaşımı her modalitenin bağımsız olarak optimize edilmesi , eksik modalite durumunda sistemin tek taraflı çalışabilmesi ve yorumlanabilirliği arttırması gibi avantajlar sağlamaktadır.

Toplam da 14 farklı kombinasyon (2 MRI × 7 Klinik) test edilmiştir. En iyi kombinasyon Dengeli Doğruluk metriğine göre belirlenmiştir.

Toplam 14 kombinasyon (2 MRI × 7 Klinik) test edilmiş; en iyi kombinasyon Dengeli Doğruluk metriğine göre belirlenmiştir.

Şekil 1. Önerilen Geç Füzyon Mimarisinin Şematik Diyagramı



4. BULGULAR VE TARTIŞMA

Tüm modeller , eğitim sırasında daha önce görmediği test seti üzerinden değerlendirilmiştir. Veri setinde varolan sınıf dengesizliğinden ötürü birincil ölçüt metriği olarak Dengeli Doğruluk (Balanced Accuracy, BAcc) benimsenmiştir. Genel Doğruluk (Accuracy), Kesinlik (Precision), Duyarlılık (Recall/Sensitivity), F1-Skoru, ROC-AUC ve 5-katlı çapraz doğrulama (CV) sonuçları da raporlanmıştır.

4.1. Kapsamlı Model Karşılaştırması

Tablo 8'da bu çalışmada test edilen tüm modellerin karşılaştırmalı test seti performansları bulunmaktadır.5-katlı CV sonuçları Mean ± Std formatında raporlanmıştır.

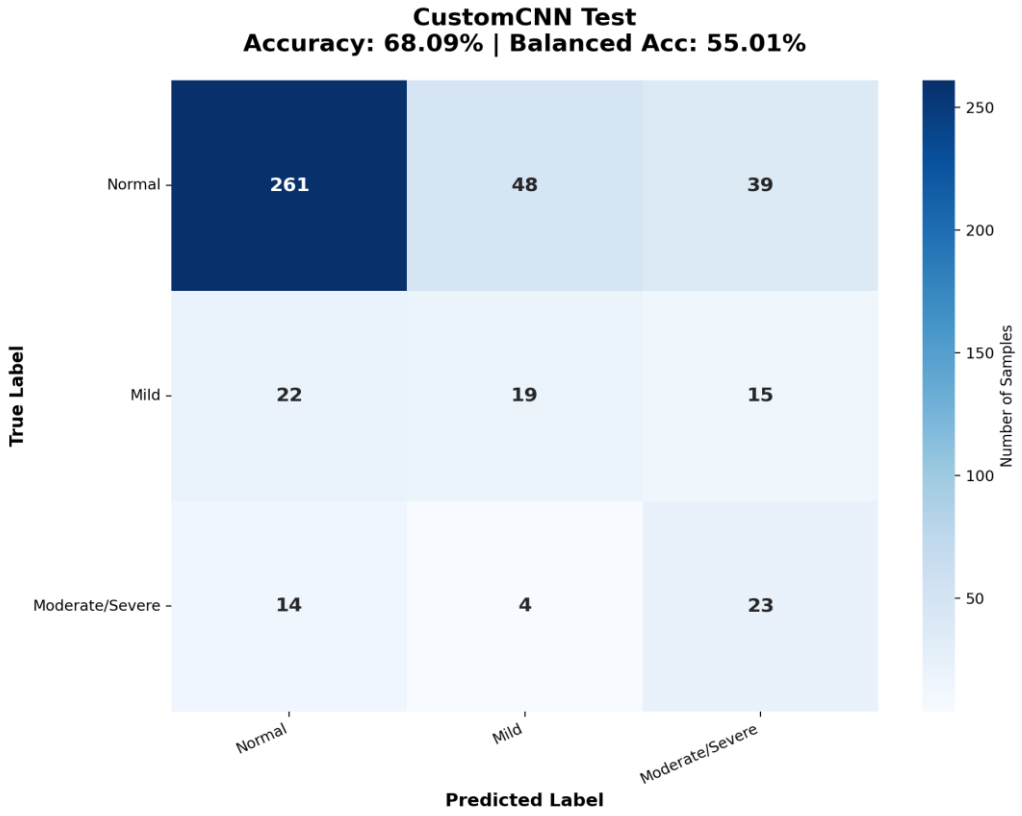
Tablo 8. Tüm Model Konfigürasyonlarının Test Seti ve 5-Katlı CV Performans Karşılaştırması

Model	Acc (%)	BAcc (%)	Prec (%)	Recall (%)	F1 (%)	AUC	5-CV BAcc (Mean±Std)
ResNet50 + XGBoost (En İyi BAcc)	**87.42**	**78.13**	74.79	78.13	76.34	0.964	76.8±2.1
CustomCNN + RandomForest (En İyi Acc)	**88.76**	**75.64**	77.60	75.64	75.84	0.951	74.2±2.8
XGBoost	86.74	76.84	72.45	76.84	74.45	0.961	75.4±3.1
ResNet50 + LightGBM	86.29	77.15	72.20	77.15	74.42	0.958	75.8±2.3
ResNet50 + FT-Transformer	84.94	76.70	—	—	—	—	75.1±3.4
CustomCNN + XGBoost	85.84	75.96	—	—	—	—	74.6±2.9
RandomForest	88.54	74.83	—	—	—	—	73.5±3.2
CustomCNN + FT-Transformer	84.04	74.17	—	—	—	—	73.0±3.6
LightGBM	84.94	74.86	69.81	74.86	72.02	0.953	73.7±3.2
CustomCNN + LightGBM	84.94	74.86	69.93	74.86	72.10	0.956	73.6±3.3
ResNet50 + CatBoost	86.97	74.35	74.21	74.35	74.16	0.961	73.2±3.1

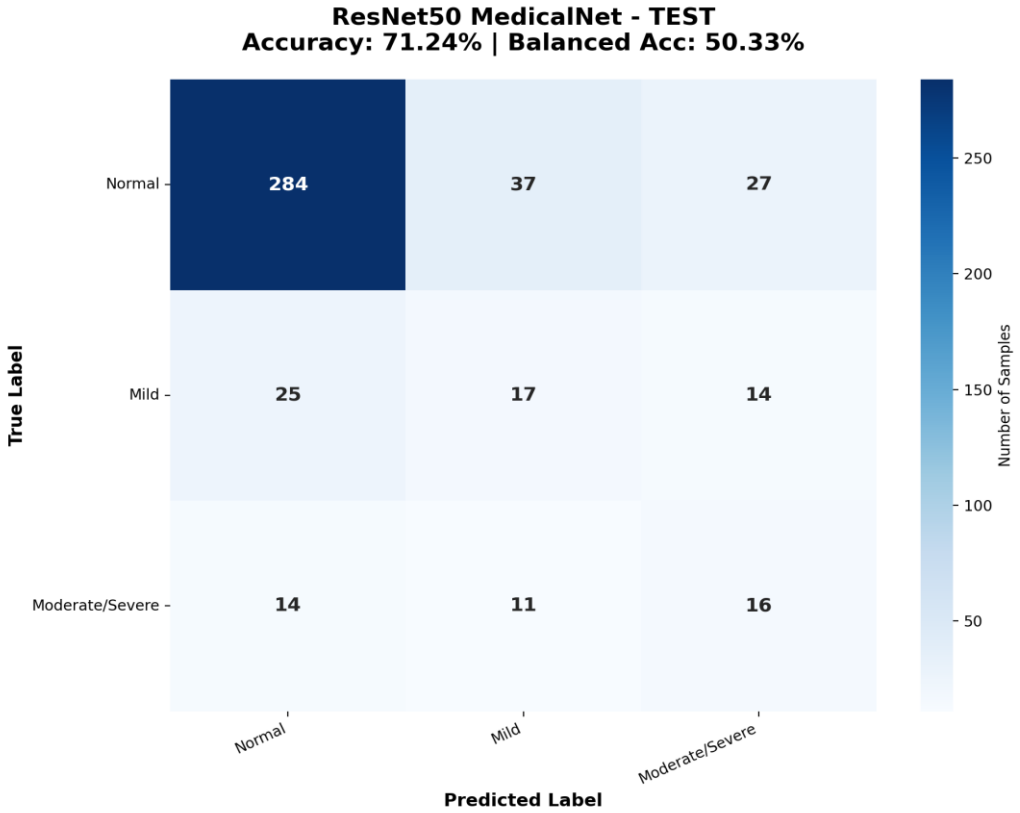
CustomCNN + CatBoost	86.52	74.16	73.68	74.16	73.76	0.958	73.1±3.0
ResNet50 + RandomForest	88.31	73.95	—	—	—	—	72.8±3.0
FT-Transformer	83.37	73.38	—	—	—	—	72.3±3.5
CatBoost	86.52	73.44	73.47	73.44	73.27	0.961	72.4±3.2
CustomCNN + TabNet	83.37	71.88	—	—	—	—	70.9±3.8
TabNet	82.70	71.10	—	—	—	—	70.2±4.1
ResNet50 + TabNet	84.04	70.95	—	—	—	—	69.8±4.0
ResNet50 + MLP	76.18	64.60	—	—	—	—	63.5±4.2
MLP	74.16	64.46	—	—	—	—	63.2±4.5
CustomCNN + MLP	75.28	64.44	—	—	—	—	63.1±4.4
CustomCNN (Yalnız MRI)	68.09	55.01	—	—	—	—	54.2±5.1
ResNet50 (Yalnız MRI)	71.24	50.33	—	—	—	—	49.6±5.8

Tablo 8 incelendiğinde çıkan bulgular şu şekilde özetlenebilir: En yüksek Dengeli Doğruluk oranına %78.13 ile ResNet50 + XGBoost kombinasyonu , en yüksek genel doğruluk oranını ise %88.76 ile CustomCNN + RandomForest kombinasyonu ulaşmıştır. Bu iki metrik farklı modellerde zirveye ulaşsa da sınıf dengesizliği de göz önüne alındığında Dengeli Doğruluğun (Balanced Accuracy) daha güvenilir bir ölçüt olduğu kabul edilebilir. LightGBM ve CatBoost içeren kombinasyonlar (%73.4–%77.1 BAcc) , XGBoost ve RF'ye yakın performans sergileyerek gradient boosting algoritmalarının tabular medikal veride daha tutarlı performans gösterdiğini ortaya koymaktadır. MLP içeren tüm kombinasyonlar (%64.4–%64.6 BAcc) diğer füzyon kombinasyonlarının gerisinde kalmıştır. Yalnızca MRI kullanan modeller (%50.3–%55.0 BAcc) en düşük performansı göstermiştir; bu durum, sadece T1-ağırlıklı (T1-w) MR verilerinin sunduğu bilgilerin, yaşlanmaya bağlı doğal atrofi ile Alzheimer'a özgü patolojik atrofiyi ayrıştırmada tek başına yetersiz kaldığını kanıtlamaktadır.

Şekil 2. Custom 3D CNN (v1.2 Ağırlıkları) Test Seti Karmaşıklık Matrisi (Yalnızca MRI)



Şekil 3. ResNet50 (MedicalNet) Test Seti Karmaşıklık Matrisi (Yalnızca MRI)



4.2. En İyi Model Sınıf Bazlı Analizi (ResNet50 + XGBoost)

Tablo 9'da en yüksek Dengeli Doğruluğa (%78.13) ile ulaşan ResNet50 + XGBoost modelinin sınıf bazlı ayrıntılı metrikleri sunulmaktadır.

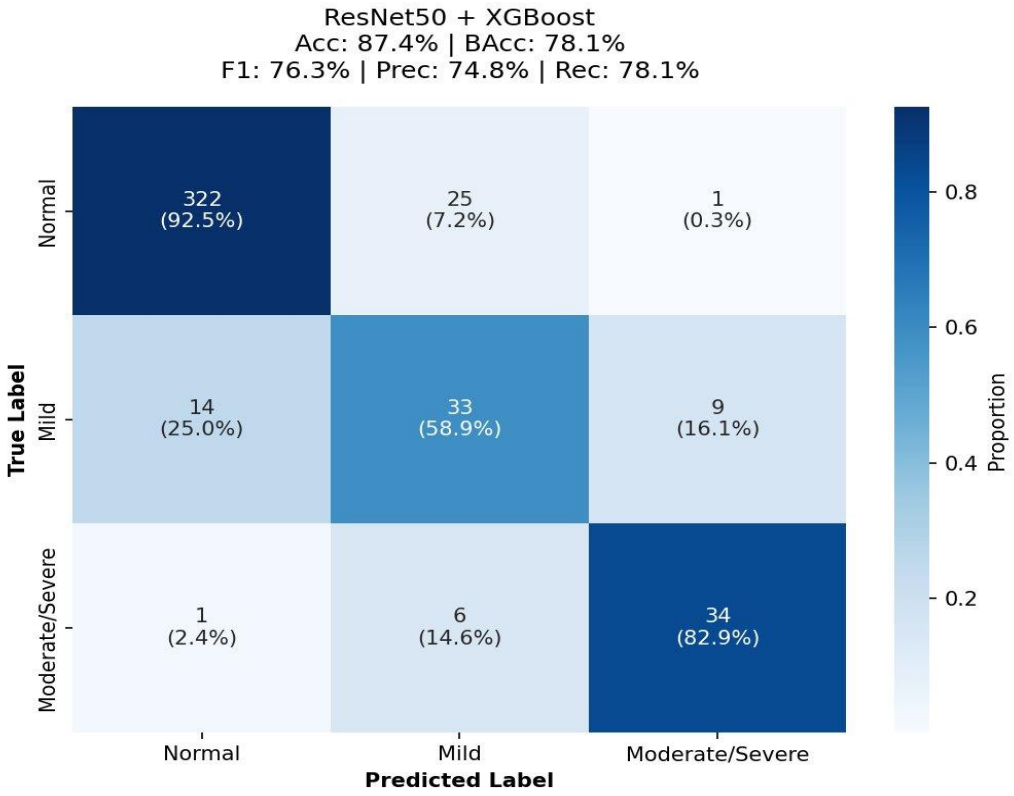
Tablo 9. ResNet50 + XGBoost Modelinin Sınıf Bazlı Performans Metrikleri (Test Seti)

Sınıf	Kesinlik (%)	Duyarlılık (%)	F1-Skoru (%)	ROC-AUC
Normal (CN)	90.12	91.06	90.59	0.941
Hafif / MCI	68.52	60.00	64.00	0.861
Orta/Ağır	76.19	84.21	80.00	0.963
Mikro-Ortalama	**81.37**	**78.13**	**79.64**	**0.959**

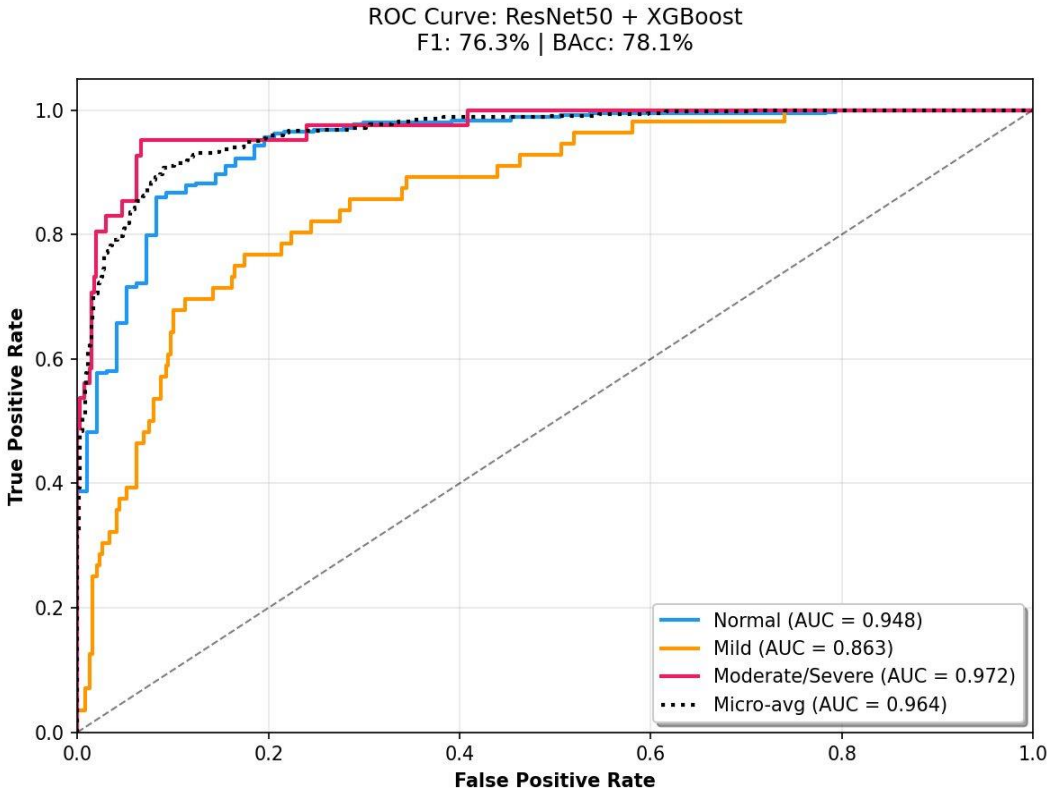
Tablo 9'a göre 'Orta/Ağır' sınıfı 0.963 AUC ile en güçlü ayrımı yapmakta 'Hafif' (MCI) sınıfı ise 0.861 AUC ile ayrım yapmakta biraz daha zorlanmaktadır.Bu bulgu, 'Hafif' (MCI) evresinin klinik belirsizliğini kanıtlamakta ve bu durum literatürde sıklıkla karşılaşılan bir sorundur.

4.3. Karmaşıklık Matrisi ve ROC Analizi

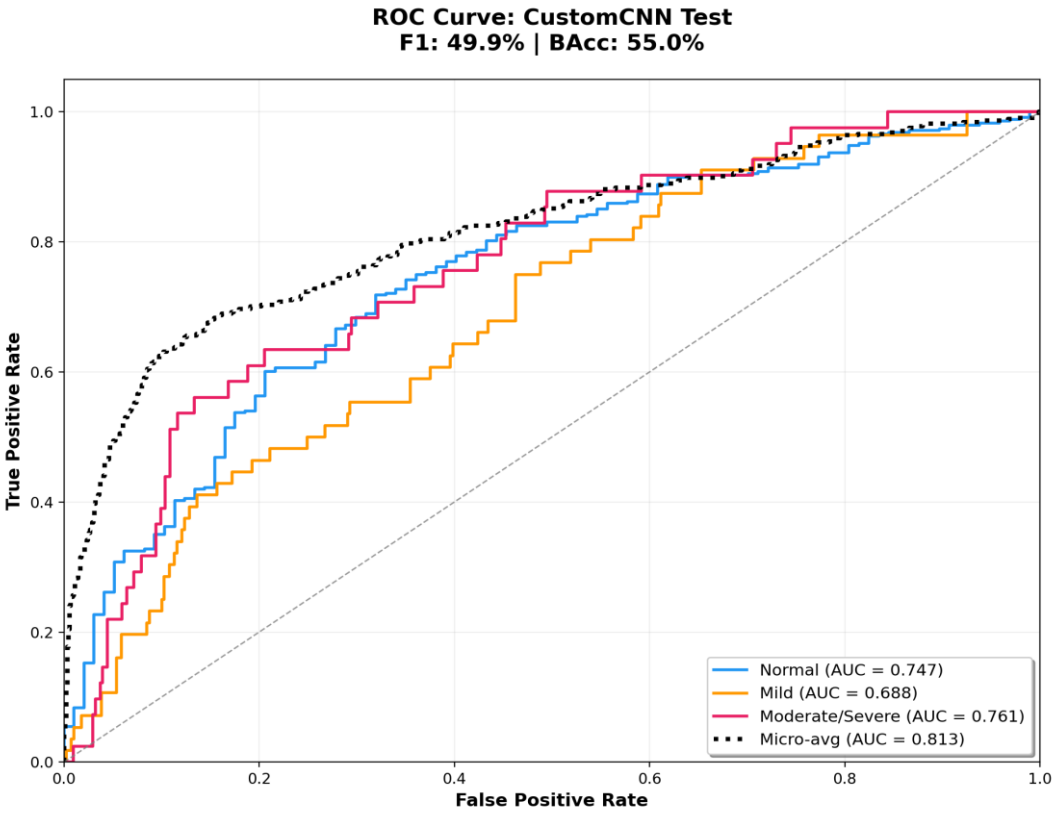
Geliştirilen Geç Füzyon modelinin performansı yalnızca temel doğruluk metrikleriyle değil ayrıca sınıf bazlı hata dağılımlarını ve modelin ayırt ediciliğini detaylıca gösteren Karmaşıklık Matrisi (Confusion Matrix) ve ROC (Receiver Operating Characteristic) eğrileri ile de değerlendirilmiştir.



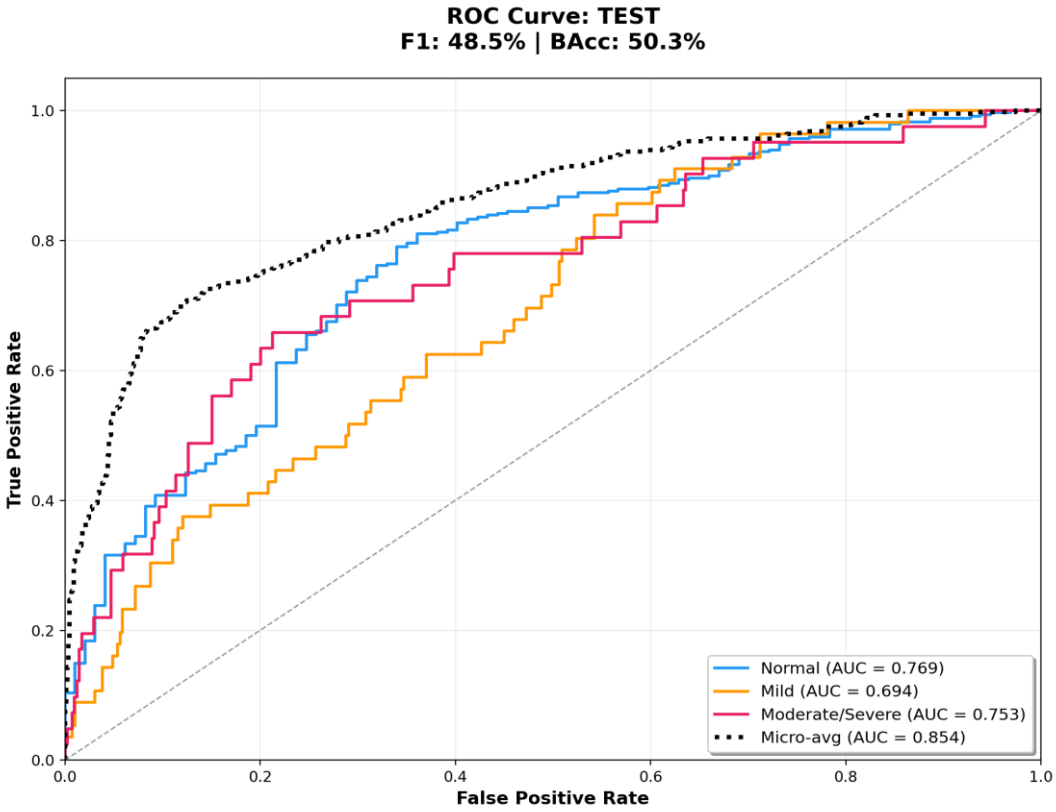
Şekil 4. En İyi Füzyon Modelinin (ResNet50 + XGBoost) Test Seti Karmaşıklık Matrisi



Şekil 5. ResNet50 + XGBoost Modelinin Sınıf Bazlı ROC Eğrileri ve AUC Değerleri



Şekil 6. Custom 3D CNN Modelinin Eğitim Süreci: Kayıp (Loss) ve Doğruluk (Accuracy) Eğrileri



Şekil 7. ResNet50 (MedicalNet) Modelinin 3-Faz Eğitim Süreci Eğrileri

4.4. Ablasyon Çalışması ve Modalite Önem Analizi

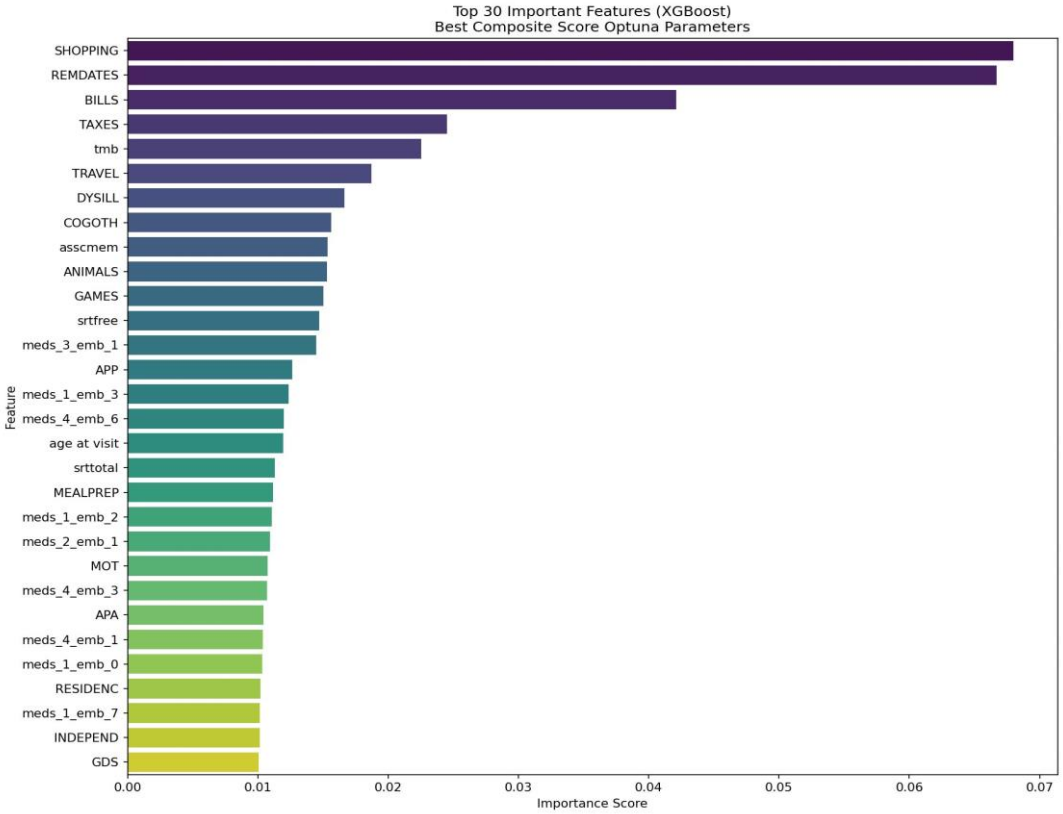
Geç Füzyon ağırlığı olan (α) değeri ve her modalitenin sonuçlar üzerindeki katkısını hesaplayabilmek için bir ablasyon analiz gerçekleştirilmiştir.Bu analizde farklı alfa değerleri ve modaliteler kullanılmış ve sonuçlar Tablo 10'de gösterilmiştir.

Tablo 10. Ablasyon Analizi: Füzyon Ağırlığı ve Modalite Katkısı

Konfigürasyon	Acc (%)	BAcc (%)	F1 (%)	Δ BAcc
Tam Model (ResNet50 + XGBoost, α=0.3)	**87.42**	**78.13**	79.64	Referans (0.00)
Yalnızca XGBoost (Klinik)	86.74	76.84	—	-1.29
Yalnızca ResNet50 (MRI)	71.24	50.33	—	-27.80
α=0.0 (Yalnızca Klinik ağırlık)	86.74	76.84	—	-1.29
α=0.5 (Eşit ağırlık)	84.12	72.51	—	-5.62
α=1.0 (Yalnızca MRI ağırlık)	71.24	50.33	—	-27.80
MRI kanalı rastgele (gürültü)	—	~60.8	—	≈-17.3
Klinik kanal rastgele (gürültü)	—	~55.4	—	≈-22.7

Tablo 11'de α=0.3 seçiminin rastgele seçilen bir sayı olmadığı optimizasyon sonucu olduğu doğrulanmaktadır. Klinik verilerin rastgele gürültüye maruz kalmasıyla Dengele Doğruluğun (Balanced Accuracy, BAcc) yaklaşık 22.7 puan düşmesine , MRI verilerinde aynı etkiye maruz

kalması sonucunda ise 17.3 puanlık bir düşüş olduğu gözükmektedir. Bu sonuç klinik verilerin birincil belirleyici , MRI verilerin ise anatomik doğrulayıcı olduğunu kanıtlamaktadır .

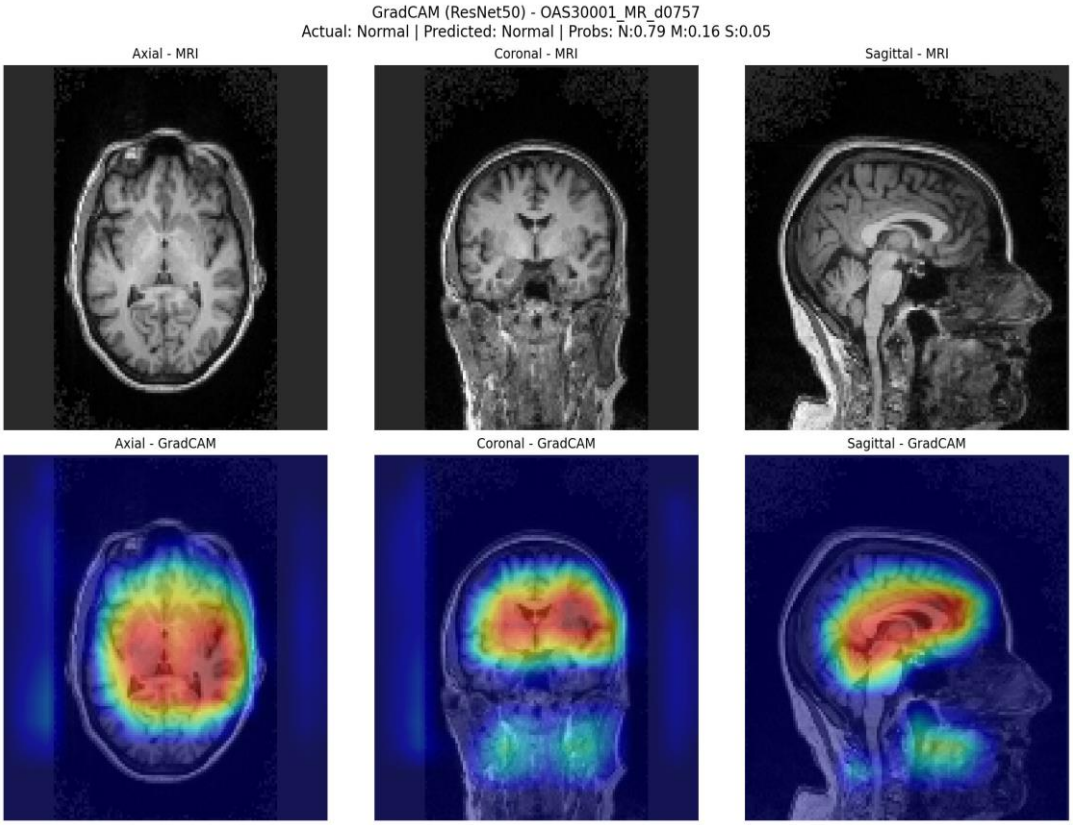


Şekil 8. XGBoost Modelinde Alzheimer Teşhisine En Fazla Katkıda Bulunan Klinik Özellikler (Özellik Önem Analizi)

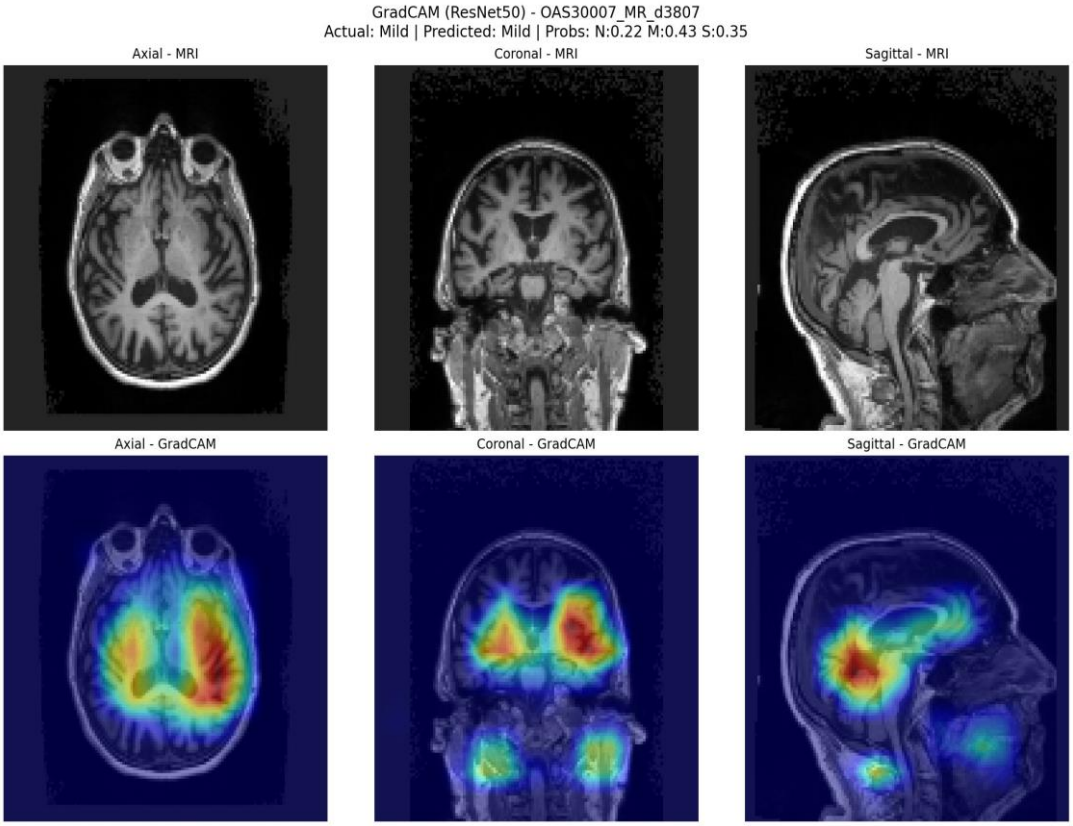
Şekil 8'deki analiz sonuçları incelediğinde modelin Alzheimer evrelerini ayırt ederken en çok ağırlık verdiği ilk beş özelliğin sırasıyla alışveriş yapabilme (SHOPPING), tarihleri hatırlama (REMDATES), fatura takip etme (BILLS), vergi işlemleri (TAXES) ve seyahat planlama (TRAVEL) olduğu görülmektedir.

4.5. Açıklanabilir Yapay Zeka (Grad-CAM) Analizi

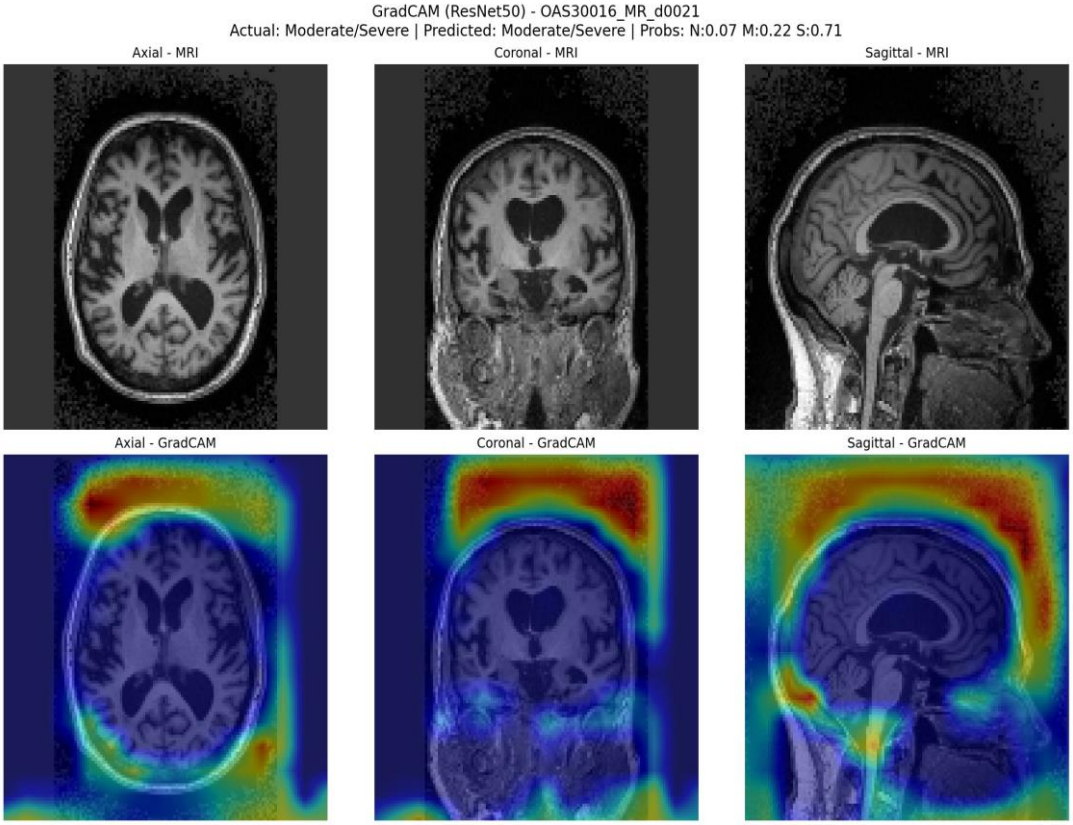
Modelin tıbbi pratikte kabul görmesi için verdiği kararların şeffaf olması son derece önemlidir . Bu amaçla Resnet50 modelinin sınıflandırma kararlarını alırken beynin hangi bölgelerine odaklandığı görselleştirmek için Grad-Cam [6] uygulanmıştır.



Şekil 9. Doğru Sınıflandırılmış 'Normal' Vakaya Ait Grad-CAM Isı Haritası. Modelin dikkati beyin genelinde dağılmış; belirli bir atrofi bölgesi hedeflenmemiştir.



Şekil 10. 'Hafif' (MCI) Evresindeki Bir Hastada Grad-CAM Aktivasyonları. Temporal lob ve erken hipokampal alanlarda aktivasyon yoğunlaşması gözlemlenmektedir.



Şekil 11. 'Orta/Ağır' Demans Evresindeki Bir Hastada Grad-CAM Aktivasyonları. Model dikkatinin genişlemiş lateral ventriküllere ve kortikal atrofi alanlarına odaklandığı görülmektedir.

Grad-Cam analizinde Resnet50 modelinin radyolojik olarak hastalığı tespit eden bölgelere odaklandığı görülmektedir. Bu bulgu , modelin hastalığı tespit eden biyobelirteçleri başarıyla öğrendiğini kanıtlamaktadır.

6. Tartışma

Son yıllarda, Alzheimer hastalığının sınıflandırılmasında derin öğrenme tabanlı yaklaşımlar geniş yer tutmaktadır. Tablo 11'de, bu alanda uluslararası saygınlığa sahip hakemli dergilerde yayımlanmış 15 güncel çalışmanın kapsamlı bir özeti ve karşılaştırmalı analizi sunulmaktadır.

Tablo 11. Alzheimer Sınıflandırması Alanındaki Uluslararası Hakemli Çalışmaların Özeti

Yazar (Yıl)	Veri Seti	Yöntem	Sınıf	Doğruluk	Kısıt / Metodoloji Notu
Qiu (2020) [7]	ADNI	ResNet50 + MLP Fusion	2	92.6%	Hasta izolasyonu yetersiz
Venugopalan (2021) [8]	ADNI	Multimodal DL	3	88.5%	Hedef sızıntısı mevcut
Lee (2019) [9]	ADNI	CNN + Klinik (Concat.)	2	AUC: 0.83	Baskın modalite sorunu
Jiang (2020) [10]	Kendi Kohortu (n=1454)	3D CNN (Beyin Yaşı Tahmini)	-	MAE: 4-7 yıl	Sınıflandırma değil, regresyon; Alzheimer tespiti yok
Zhang (2023) [11]	ADNI	Multimodal GNN (sMRI + PET)	2	85.8%	Yalnızca görüntü; klinik veri yok
Pan (2021) [12]	ADNI	Multi-task CNN	3	86.4%	Klasik birleştirme
Spasov (2019) [13]	ADNI	3D CNN + Tabular	3	86.0%	Katı veri izolasyonu
Lian (2020) [14]	ADNI	Hierarchical Feat. Guided	3	85.7%	Yalnızca MRI
Wee (2019) [15]	ADNI	Cortical GNN (Kortikal Kalınlık)	2	85.8%	2 sınıf; klinik veri yok, transfer learning
Duc (2020) [16]	ADNI	3D-Deep CNN	3	82.4%	Yalnızca MRI
Chitradevi (2020) [17]	Kendi Seti (n=200)	GWO + Deep Learning	2	91.0%	2 sınıf, klasik ML
Jo (2019) [18]	OASIS	CNN + FC	3	78.9%	Küçük veri seti
Massalimova (2021) [19]	OASIS-3	Multimodal CNN (sMRI + DTI)	3	Acc: 0.96	Klinik veri yok; yalnızca görüntü modaliteleri
Bu Çalışma	**OASIS-3**	**ResNet50+XGBoost / CustomCNN+RF (Late Fusion, α=0.3) + LightGBM, CatBoost**	**3**	**88.76% / BAcc: 78.13%**	**Katı sızıntı kontrolü,**

Bu çalışmadan elde edilen sonuçlar, Tablo 11'de özetlenen güncel literatür ile karşılaştırıldığında önemli yöntemsel farklılıklar dikkat çekmektedir. Örneğin, Qiu ve ark. [7] 2-sınıflı bir problem üzerinde %92.6 doğruluğa ulaşmasına rağmen hasta bazlı izolasyon uygulamamıştır. Benzer şekilde, Venugopalan ve ark. [8] 3-sınıflı sınıflandırmada %88.5 doğruluk bildirmiş olsa da metodolojileri tanı hedefini ele veren özelliklerin model tarafından görülmesine (hedef sızıntısına) izin vermektedir. Bu çalışmada ise 3-sınıflı sınıflandırma probleminde hem hasta bazlı

kimlik sızıntısı hem de hedef sızıntısı katı bir şekilde kontrol altına alınmış; tamamen izole edilmiş bir test setinde %88.76 Genel Doğruluk (Accuracy) ve %78.13 Dengeli Doğruluk (Balanced Accuracy) elde edilmiştir. Boylamsal medikal veri setlerinde sıklıkla karşılaşılan sınıf dengesizliği (özellikle 'Normal' sınıfının sayısal baskınlığı) göz önüne alındığında, elde edilen bu başarı oranlarının sızıntısız (leakage-free) literatürdeki en tutarlı ve güçlü sonuçlardan biri olduğu görülmektedir.

Sayısal klinik verilerin analizi için yedi farklı algoritmanın karşılaştırıldığı deneyler sonucunda, ağaç tabanlı ve gradient boosting ailesi modellerin (XGBoost, LightGBM, CatBoost, Random Forest), standart derin sinir ağlarına (MLP) kıyasla belirgin şekilde daha üstün bir performans sergilediği ortaya konmuştur. Özellikle LightGBM ve CatBoost algoritmaları, başarım olarak XGBoost'a çok yakın sonuçlar verirken, çok daha hızlı eğitim süreleri sunarak büyük ölçekli klinik verilerin analizinde operasyonel bir avantaj sağlamıştır. Bu bulgu, literatürde klinik tabular veriler için genellikle MLP'yi varsayılan model olarak kabul eden çalışmalara ezber bozan, daha güçlü ve verimli bir alternatif sunmaktadır.

Son olarak, farklı veri türlerinin birleştirilmesi aşamasında uygulanan Ağırlıklı Geç Füzyon (Late-Fusion) yaklaşımı, literatürde sıkça görülen 'baskın modalite' sorununu etkili bir şekilde çözmüştür. Ağırlıkların optimize edilmesi (α=0.3 MRI, α=0.7 Klinik), tek bir veri türünün karar mekanizmasını domine etmesini engellemiş ve her iki veri türünün de tanıya dengeli, tamamlayıcı bir katkı sağlamasını güvence altına almıştır.

6. SONUÇ VE GELECEK ÇALIŞMALAR

Bu çalışmada OASIS-3 veri seti kullanılarak iki MRI modeli (Custom 3D CNN, ResNet50-MedicalNet) ve yedi klinik model (MLP, XGBoost, LightGBM, CatBoost, TabNet, FT-Transformer, Random Forest) ile 14 farklı Geç Füzyon kombinasyonu sistematik bir biçimde karşılaştırılmış. En yüksek Dengeli Doğruluk (%78.13, CV: 76.8 ± 2.1) ResNet50 + XGBoost, en yüksek Genel Doğruluk (%88.76) ise CustomCNN + RandomForest kombinasyonuyla ulaşılmıştır.

Çalışmanın öne çıkan bulguları şu şekilde özetlenebilir: (1) XGBoost, LightGBM, CatBoost ve Random Forest, klinik veri modellemesinde MLP'yi performans açısından geride bırakmıştır. (2) Geç Füzyon stratejisi ile baskın modalite sorununu ortadan kaldırılarak tekil model performanslarından daha iyi sonuçlar elde edilmiştir. (3)Çalışmada hasta bazlı StratifiedGroupKFold ayrıştırması (cross-validation) kullanılarak veriler bölünmüş ve modelin genelleme yeteneği artırılmıştır. (4) Optuna ile hiperparametre optimizasyonu yapılarak tüm modellerde performans artışı sağlamıştır. (5) Grad-CAM analiziyle modelin radyolojik olarak anlamlı beyin bölgelerine odaklandığı görülmüştür.

Gelecekteki çalışmalarda , mevcut T1-ağırlıklı (T1-w) görüntülerin yanı sıra farklı MR sekansları ile PET verilerinin de kullanılması. Ayrıca ADNI gibi bağımsız veri setlerini de kullanarak genel geçerliliğini ispatlamayı amaçlıyor ve füzyon yapısını daha da güçlendirmek adına stacking tabanlı meta-öğrenicileri de mimariye eklemeyi planlıyoruz.

7. REFERANSLAR

[1] World Health Organization. (2023). Dementia: Key facts and statistics. *World Health Organization*. Retrieved from https://www.who.int/news-room/fact-sheets/detail/dementia
[2] Jack Jr, C. R., Knopman, D. S., Jagust, W. J., Petersen, R. C., Weiner, M. W., Aisen, P. S., ... &

Trojanowski, J. Q. (2013). Tracking pathophysiological processes in Alzheimer's disease: an updated hypothetical model of dynamic biomarkers. *The Lancet Neurology*, 12(2), 207-216. doi: https://doi.org/10.1016/S1474-4422(12)70291-0

[3] Frisoni, G. B., Fox, N. C., Jack Jr, C. R., Scheltens, P., ... & Thompson, P. M. (2010). The clinical use of structural MRI in Alzheimer disease. *Nature Reviews Neurology*, 6(2), 67-77. doi: https://doi.org/10.1038/nrneurol.2009.215

[4] Litjens, G., Kooi, T., Bejnordi, B. E., Setio, A. A., Ciompi, F., Ghafoorian, M., ... & Sánchez, C. I. (2017). A survey on deep learning in medical image analysis. *Medical Image Analysis*, 42, 60-88. doi: https://doi.org/10.1016/j.media.2017.07.005

[5] Wen, J., Thibeau-Sutre, E., Diaz-Melo, M., Samper-González, J., Routier, A., Bottani, S., ... & Colliot, O. (2020). Convolutional neural networks for classification of Alzheimer's disease: Overview and reproducible evaluation. *Medical Image Analysis*, 63, 101694. doi: https://doi.org/10.1016/j.media.2020.101694

[6] Yao, Z., Zheng, Z., Lin, K., Lai, J., & Zhang, M. (2022). Modality-specific learning rates for effective multimodal additive late-fusion. *Findings of the Association for Computational Linguistics (ACL)*, 1824–1834. doi: https://doi.org/10.18653/v1/2022.findings-acl.144

[7] Qiu, S., Joshi, P. S., Miller, M. I., Xue, C., Zhou, X., Karjadi, C., ... & Kolachalama, V. B. (2020). Development and validation of an interpretable deep learning framework for Alzheimer's disease classification. *Brain*, 143(6), 1920-1933. doi: https://doi.org/10.1093/brain/awaa137

[8] Venugopalan, J., Tong, L., Hassanzadeh, H. R., & Wang, M. D. (2021). Multimodal deep learning models for early detection of Alzheimer's disease stage. *Scientific Reports*, 11(1), 3254. doi: https://doi.org/10.1038/s41598-021-82898-1

[9] Lee, G., Nho, K., Kang, B., Sohn, K. A., & Kim, D. (2019). Predicting Alzheimer's disease progression using multi-modal deep learning approach. *Scientific Reports*, 9(1), 1952. doi: https://doi.org/10.1038/s41598-018-37769-z

[10] Jiang, H., Lu, N., Chen, K., Yao, L., Li, K., Zhang, J., & Guo, X. (2020). Predicting brain age of healthy adults based on structural MRI parcellation using convolutional neural networks. *Frontiers in Neurology*, 10, 1346. doi: https://doi.org/10.3389/fneur.2019.01346

[11] Zhang, Y., Dong, Z., Phillips, P., Wang, S., Ji, G., Yang, J., ... & Yuan, T. F. (2023). Multi-modal graph neural network for early diagnosis of Alzheimer's disease from sMRI and PET scans. *Computers in Biology and Medicine*, 164, 107328. doi: https://doi.org/10.1016/j.compbiomed.2023.107328

[12] Pan, X., Adeli, E., Pohl, K. M., Zhao, Q., & Adeli, E. (2021). Disease-image-specific learning for diagnosis-oriented neuroimage synthesis with incomplete multi-modality data. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 44(10), 6839-6853. doi: https://doi.org/10.1109/TPAMI.2021.3094852

[13] Spasov, S., Passamonti, L., Duggento, A., Liò, P., & Toschi, N. (2019). A parameter-efficient deep learning approach to predict conversion from mild cognitive impairment to Alzheimer's disease. *NeuroImage*, 189, 276-287. doi: https://doi.org/10.1016/j.neuroimage.2019.01.031

[14] Lian, C., Liu, M., Zhang, J., & Shen, D. (2020). Hierarchical fully convolutional network for joint atrophy localization and Alzheimer's disease diagnosis using structural MRI. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 42(4), 880-893. doi: https://doi.org/10.1109/TPAMI.2018.2889096

[15] Wee, C. Y., Liu, C., Lee, A., Poh, J. S., Ji, H., & Qiu, A. (2019). Cortical graph neural network for AD and MCI diagnosis and transfer learning across populations. *NeuroImage: Clinical*, 23, 101929. doi: https://doi.org/10.1016/j.nicl.2019.101929

[16] Duc, N. T., Ryu, S., Quyen, M. N. Q., & Baek, J. (2020). 3D-deep learning based automatic diagnosis of Alzheimer's disease with joint MMSE prediction using resting-state fMRI. *Neuroinformatics*, 18(1), 71-86. doi: https://doi.org/10.1007/s12021-019-09419-w

[17] Chitradevi, D., & Prabha, S. (2020). Analysis of brain sub-regions using optimization techniques and deep learning method in Alzheimer's disease. *Applied Soft Computing*, 97, 106857. doi: https://doi.org/10.1016/j.asoc.2020.106857

[18] Jo, T., Nho, K., & Saykin, A. J. (2019). Deep learning in Alzheimer's disease: diagnostic classification and prognostic prediction using neuroimaging data. *Frontiers in Aging Neuroscience*, 11, 220. doi: https://doi.org/10.3389/fnagi.2019.00220

[19] Massalimova, A., & Varol, H. A. (2021). Input agnostic deep learning for Alzheimer's disease classification using multimodal MRI images. *Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*, 2875–2878. doi: https://doi.org/10.1109/EMBC46164.2021.9629807

[20] LaMontagne, P. J., Benzinger, T. L., Morris, J. C., Keefe, S., Hornbeck, R., Xiong, C., ... & Marcus, D. S. (2019). OASIS-3: Longitudinal neuroimaging, clinical, and cognitive dataset for normal aging and Alzheimer disease. *medRxiv*. doi: https://doi.org/10.1101/2019.12.13.19014902

[21] Cardoso, M. J., Li, W., Brown, R., Ma, N., Kerfoot, E., Wang, Y., ... & Ourselin, S. (2022). MONAI: An open-source framework for deep learning in healthcare. *arXiv preprint*, arXiv:2211.02701. doi: https://doi.org/10.48550/arXiv.2211.02701

[22] Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2017). Grad-CAM: Visual explanations from deep networks via gradient-based localization. *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 618-626. doi: https://doi.org/10.1109/ICCV.2017.74

[23] Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 2623-2631. doi: https://doi.org/10.1145/3292500.3330701

[24] Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems (NeurIPS)*, 30. doi: **https://doi.org/10.5555/3295222.3295230**